量化分析师的Python日记【第3天：一大波金融Library来袭之numpy篇】

###接下来要给大家介绍的系列中包含了Python在量化金融中运用最广泛的几个Library:

numpy

scipy

pandas

matplotlib

会给初学者一一介绍

###NumPy 简介

####一、NumPy是什么？

量化分析的工作涉及到大量的数值运算，一个高效方便的科学计算工具是必不可少的。Python语言一开始并不是设计为科学计算使用的语言，随着越来越多的人发现Python的易用性，逐渐出现了关于Python的大量外部扩展，NumPy (Numeric Python)就是其中之一。NumPy提供了大量的数值编程工具，可以方便地处理向量、矩阵等运算，极大地便利了人们在科学计算方面的工作。另一方面，Python是免费，相比于花费高额的费用使用Matlab，NumPy的出现使Python得到了更多人的青睐。

我们可以简单看一下如何开始使用NumPy：

```
1 import numpy
2 numpy.version.full_version
```

查看全部 ()

```
'1.8.0'
```

我们使用了"import"命令导入了NumPy，并使用numpy.version.full_version查出了量化实验室里使用的NumPy版本为1.8.0。在往后的介绍中，我们将大量使用NumPy中的函数，每次都添加numpy在函数前作为前缀比较费劲，在之前的介绍中，我们提及了引入外部扩展模块时的小技巧，可以使用"from numpy import *"解决这一问题。

那么问题解决了？慢！Python的外部扩展成千上万，在使用中很可能会import好几个外部扩展模块，如果某个模块包含的属性和方法与另一个模块同名，就必须使用import module来避免名字的冲突。即所谓的名字空间（namespace）混淆了，所以这前缀最好还是带上。

那有没有简单的办法呢？有的，我们可以在import扩展模块时添加模块在程序中的别名，调用时就不必写成全名了，例如，我们使用"np"作为别名并调用version.full_version函数：

```
1 import numpy as np
2 np.version.full_version
```

查看全部 ()

```
'1.8.0'
```

####二、初窥NumPy对象：数组

NumPy中的基本对象是同类型的多维数组（homogeneous multidimensional array），这和C++中的数组是一致的，例如字符型和数值型就不可共存于同一个数组中。先上例子：

```
1 a = np.arange(20)
```
查看全部 ()

这里我们生成了一个一维数组a，从0开始，步长为1，长度为20。Python中的计数是从0开始的，R和Matlab的使用者需要小心。可以使用print查看：

```
1 print a
```
查看全部 ()

```
[ 0  1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19]
```

我们可以通过"type"函数查看a的类型，这里显示a是一个array：

```
1 type(a)
```
查看全部 ()

```
numpy.ndarray
```

通过函数"reshape"，我们可以重新构造一下这个数组，例如，我们可以构造一个4*5的二维数组，其中"reshape"的参数表示各维度的大小，且按各维顺序排列（两维时就是按行排列，这和R中按列是不同的）：

```
1 a = a.reshape(4, 5)
2 print a
```
查看全部 ()

```
[[ 0  1  2  3  4]
 [ 5  6  7  8  9]
 [10 11 12 13 14]
 [15 16 17 18 19]]
```

构造更高维的也没问题:

```
1 a = a.reshape(2, 2, 5)
2 print a
```
查看全部 ()

```
[[[ 0  1  2  3  4]
  [ 5  6  7  8  9]]

 [[10 11 12 13 14]
  [15 16 17 18 19]]]
```

既然a是array，我们还可以调用array的函数进一步查看a的相关属性："ndim"查看维度；"shape"查看各维度的大小；"size"查看全部的元素个数，等于各维度大小的乘积；"dtype"可查看元素类型；"dsize"查看元素占位（bytes）大小。

```
1 a.ndim
```

查看全部 ()

```
3
```

```
1 a.shape
```

查看全部 ()

```
(2, 2, 5)
```

```
1 a.size
```

查看全部 ()

```
20
```

```
1 a.dtype
```

查看全部 ()

```
dtype('int64')
```

####三、创建数组

数组的创建可通过转换列表实现，高维数组可通过转换嵌套列表实现：

```
1 raw = [0,1,2,3,4]
2 a = np.array(raw)
3 a
```

查看全部 ()

```
array([0, 1, 2, 3, 4])
```

```
1 raw = [[0,1,2,3,4], [5,6,7,8,9]]
2 b = np.array(raw)
3 b
```

查看全部 ()

```
array([[0, 1, 2, 3, 4],
       [5, 6, 7, 8, 9]])
```

一些特殊的数组有特别定制的命令生成，如4*5的全零矩阵：

```
d = (4, 5)
np.zeros(d)
```

查看全部 ()

```
array([[ 0.,  0.,  0.,  0.,  0.],
       [ 0.,  0.,  0.,  0.,  0.],
       [ 0.,  0.,  0.,  0.,  0.],
       [ 0.,  0.,  0.,  0.,  0.]])
```

默认生成的类型是浮点型，可以通过指定类型改为整型：

```
d = (4, 5)
np.ones(d, dtype=int)
```

查看全部 ()

```
array([[1, 1, 1, 1, 1],
       [1, 1, 1, 1, 1],
       [1, 1, 1, 1, 1],
       [1, 1, 1, 1, 1]])
```

[0, 1)区间的随机数数组：

```
np.random.rand(5)
```

查看全部 ()

```
array([ 0.93807818,  0.45307847,  0.90732828,  0.36099623,  0.71981451])
```

####四、数组操作

简单的四则运算已经重载过了，全部的'+'，'-'，'*'，'/'运算都是基于全部的数组元素的，以加法为例：

```
a = np.array([[1.0, 2], [2, 4]])
print "a:"
print a
b = np.array([[3.2, 1.5], [2.5, 4]])
print "b:"
print b
print "a+b:"
```

```
8 print a+b
```

查看全部 ()

```
a:
[[ 1.  2.]
 [ 2.  4.]]
b:
[[ 3.2  1.5]
 [ 2.5  4. ]]
a+b:
[[ 4.2  3.5]
 [ 4.5  8. ]]
```

这里可以发现，a中虽然仅有一个与元素是浮点数，其余均为整数，在处理中Python会自动将整数转换为浮点数（因为数组是同质的），并且，两个二维数组相加要求各维度大小相同。当然，NumPy里这些运算符也可以对标量和数组操作，结果是数组的全部元素对应这个标量进行运算，还是一个数组：

```
1 print "3 * a:"
2 print 3 * a
3 print "b + 1.8:"
4 print b + 1.8
```

查看全部 ()

```
3 * a:
[[  3.   6.]
 [  6.  12.]]
b + 1.8:
[[ 5.   3.3]
 [ 4.3  5.8]]
```

类似C++，'+='、'-='、'*='、'/='操作符在NumPy中同样支持：

```
1 a /= 2
2 print a
```

查看全部 ()

```
[[ 0.5  1. ]
 [ 1.   2. ]]
```

开根号求指数也很容易：

```
1 print "a:"
2 print a
3 print "np.exp(a):"
4 print np.exp(a)
5 print "np.sqrt(a):"
```

```
print np.sqrt(a)
print "np.square(a):"
print np.square(a)
print "np.power(a, 3):"
print np.power(a, 3)
```

查看全部 ()

```
a:
[[ 0.5  1. ]
 [ 1.   2. ]]
np.exp(a):
[[ 1.64872127  2.71828183]
 [ 2.71828183  7.3890561 ]]
np.sqrt(a):
[[ 0.70710678  1.        ]
 [ 1.          1.41421356]]
np.square(a):
[[ 0.25  1.  ]
 [ 1.    4.  ]]
np.power(a, 3):
[[ 0.125  1.   ]
 [ 1.     8.   ]]
```

需要知道二维数组的最大最小值怎么办？想计算全部元素的和、按行求和、按列求和怎么办？for循环吗？不，NumPy的ndarray类已经做好函数了：

```
a = np.arange(20).reshape(4,5)
print "a:"
print a
print "sum of all elements in a: " + str(a.sum())
print "maximum element in a: " + str(a.max())
print "minimum element in a: " + str(a.min())
print "maximum element in each row of a: " + str(a.max(axis=1))
print "minimum element in each column of a: " + str(a.min(axis=0))
```

查看全部 ()

```
a:
[[ 0  1  2  3  4]
 [ 5  6  7  8  9]
 [10 11 12 13 14]
 [15 16 17 18 19]]
sum of all elements in a: 190
maximum element in a: 19
minimum element in a: 0
maximum element in each row of a: [ 4  9 14 19]
minimum element in each column of a: [0 1 2 3 4]
```

科学计算中大量使用到矩阵运算，除了数组，NumPy同时提供了矩阵对象（matrix）。矩阵对象和数组的主要有两点差别：一是矩阵是二维的，而数组的可以是任意正整数维；二是矩阵的'*'操作符进行的是矩阵乘法，乘号左侧的矩阵列和乘号右侧的矩阵行要相等，而在数组中'*'操作符进行的是每一元素的对应相乘，乘号两侧的数组每一维大小需要一致。数组可以通过asmatrix或者mat转换为矩阵，或者直接生成也可以：

```
a = np.arange(20).reshape(4, 5)
a = np.asmatrix(a)
print type(a)

b = np.matrix('1.0 2.0; 3.0 4.0')
print type(b)
```

查看全部 ()

```
<class 'numpy.matrixlib.defmatrix.matrix'>
<class 'numpy.matrixlib.defmatrix.matrix'>
```

再来看一下矩阵的乘法，这使用arange生成另一个矩阵b，arange函数还可以通过arange(起始，终止，步长)的方式调用生成等差数列，注意含头不含尾。

```
b = np.arange(2, 45, 3).reshape(5, 3)
b = np.mat(b)
print b
```

查看全部 ()

```
[[ 2  5  8]
 [11 14 17]
 [20 23 26]
 [29 32 35]
 [38 41 44]]
```

有人要问了，arange指定的是步长，如果想指定生成的一维数组的长度怎么办？好办，"linspace"就可以做到：

```
np.linspace(0, 2, 9)
```

查看全部 ()

```
array([ 0.  ,  0.25,  0.5 ,  0.75,  1.  ,  1.25,  1.5 ,  1.75,  2.  ])
```

回到我们的问题，矩阵a和b做矩阵乘法：

```
print "matrix a:"
print a
print "matrix b:"
print b
c = a * b
```

```
print "matrix c:"
print c
```

查看全部 ()

```
matrix a:
[[ 0  1  2  3  4]
 [ 5  6  7  8  9]
 [10 11 12 13 14]
 [15 16 17 18 19]]
matrix b:
[[ 2  5  8]
 [11 14 17]
 [20 23 26]
 [29 32 35]
 [38 41 44]]
matrix c:
[[ 290  320  350]
 [ 790  895 1000]
 [1290 1470 1650]
 [1790 2045 2300]]
```

####五、数组元素访问

数组和矩阵元素的访问可通过下标进行，以下均以二维数组（或矩阵）为例：

```
a = np.array([[3.2, 1.5], [2.5, 4]])
print a[0][1]
print a[0, 1]
```

查看全部 ()

```
1.5
1.5
```

可以通过下标访问来修改数组元素的值：

```
b = a
a[0][1] = 2.0
print "a:"
print a
print "b:"
print b
```

查看全部 ()

```
a:
[[ 3.2  2. ]
 [ 2.5  4. ]]
```

```
b:
[[ 3.2  2. ]
 [ 2.5  4. ]]
```

现在问题来了，明明改的是a[0][1]，怎么连b[0][1]也跟着变了？这个陷阱在Python编程中很容易碰上，其原因在于Python不是真正将a复制一份给b，而是将b指到了a对应数据的内存地址上。想要真正的复制一份a给b，可以使用copy：

```
1 a = np.array([[3.2, 1.5], [2.5, 4]])
2 b = a.copy()
3 a[0][1] = 2.0
4 print "a:"
5 print a
6 print "b:"
7 print b
```

查看全部 ()

```
a:
[[ 3.2  2. ]
 [ 2.5  4. ]]
b:
[[ 3.2  1.5]
 [ 2.5  4. ]]
```

若对a重新赋值，即将a指到其他地址上，b仍在原来的地址上：

```
1 a = np.array([[3.2, 1.5], [2.5, 4]])
2 b = a
3 a = np.array([[2, 1], [9, 3]])
4 print "a:"
5 print a
6 print "b:"
7 print b
```

查看全部 ()

```
a:
[[2 1]
 [9 3]]
b:
[[ 3.2  1.5]
 [ 2.5  4. ]]
```

利用':'可以访问到某一维的全部数据，例如取矩阵中的指定列：

```
1 a = np.arange(20).reshape(4, 5)
2 print "a:"
```

```
print a
print "the 2nd and 4th column of a:"
print a[:,[1,3]]
```

查看全部 ()

```
a:
[[ 0  1  2  3  4]
 [ 5  6  7  8  9]
 [10 11 12 13 14]
 [15 16 17 18 19]]
the 2nd and 4th column of a:
[[ 1  3]
 [ 6  8]
 [11 13]
 [16 18]]
```

稍微复杂一些，我们尝试取出满足某些条件的元素，这在数据的处理中十分常见，通常用在单行单列上。下面这个例子是将第一列大于5的元素（10和15）对应的第三列元素（12和17）取出来：

```
a[:, 2][a[:, 0] > 5]
```

查看全部 ()

```
array([12, 17])
```

可使用where函数查找特定值在数组中的位置：

```
loc = numpy.where(a==11)
print loc
print a[loc[0][0], loc[1][0]]
```

查看全部 ()

```
(array([2]), array([1]))
11
```

####六、数组操作

还是拿矩阵（或二维数组）作为例子，首先来看矩阵转置：

```
a = np.random.rand(2,4)
print "a:"
print a
a = np.transpose(a)
print "a is an array, by using transpose(a):"
print a
b = np.random.rand(2,4)
b = np.mat(b)
```

```
 9 print "b:"
10 print b
11 print "b is a matrix, by using b.T:"
12 print b.T
```

查看全部()

```
a:
[[ 0.17571282  0.98510461  0.94864387  0.50078988]
 [ 0.09457965  0.70251658  0.07134875  0.43780173]]
a is an array, by using transpose(a):
[[ 0.17571282  0.09457965]
 [ 0.98510461  0.70251658]
 [ 0.94864387  0.07134875]
 [ 0.50078988  0.43780173]]
b:
[[ 0.09653644  0.46123468  0.50117363  0.69752578]
 [ 0.60756723  0.44492537  0.05946373  0.4858369 ]]
b is a matrix, by using b.T:
[[ 0.09653644  0.60756723]
 [ 0.46123468  0.44492537]
 [ 0.50117363  0.05946373]
 [ 0.69752578  0.4858369 ]]
```

矩阵求逆：

```
 1 import numpy.linalg as nlg
 2 a = np.random.rand(2,2)
 3 a = np.mat(a)
 4 print "a:"
 5 print a
 6 ia = nlg.inv(a)
 7 print "inverse of a:"
 8 print ia
 9 print "a * inv(a)"
10 print a * ia
```

查看全部()

```
a:
[[ 0.86211266  0.6885563 ]
 [ 0.28798536  0.70810425]]
inverse of a:
[[ 1.71798445 -1.6705577 ]
 [-0.69870271  2.09163573]]
a * inv(a)
[[ 1.  0.]
 [ 0.  1.]]
```

求特征值和特征向量

```
a = np.random.rand(3,3)
eig_value, eig_vector = nlg.eig(a)
print "eigen value:"
print eig_value
print "eigen vector:"
print eig_vector
```

查看全部 ()

```
eigen value:
[ 1.35760609  0.43205379 -0.53470662]
eigen vector:
[[-0.76595379 -0.88231952 -0.07390831]
 [-0.55170557  0.21659887 -0.74213622]
 [-0.33005418  0.41784829  0.66616169]]
```

按列拼接两个向量成一个矩阵：

```
a = np.array((1,2,3))
b = np.array((2,3,4))
print np.column_stack((a,b))
```

查看全部 ()

```
[[1 2]
 [2 3]
 [3 4]]
```

在循环处理某些数据得到结果后，将结果拼接成一个矩阵是十分有用的，可以通过vstack和hstack完成：

```
a = np.random.rand(2,2)
b = np.random.rand(2,2)
print "a:"
print a
print "b:"
print a
c = np.hstack([a,b])
d = np.vstack([a,b])
print "horizontal stacking a and b:"
print c
print "vertical stacking a and b:"
print d
```

查看全部 ()

```
a:
```

```
[[ 0.6738195   0.4944045 ]
 [ 0.25702675  0.15422012]]
b:
[[ 0.6738195   0.4944045 ]
 [ 0.25702675  0.15422012]]
horizontal stacking a and b:
[[ 0.6738195   0.4944045   0.28058267  0.0967197 ]
 [ 0.25702675  0.15422012  0.55191041  0.04694485]]
vertical stacking a and b:
[[ 0.6738195   0.4944045 ]
 [ 0.25702675  0.15422012]
 [ 0.28058267  0.0967197 ]
 [ 0.55191041  0.04694485]]
```

####七、缺失值

缺失值在分析中也是信息的一种，NumPy提供nan作为缺失值的记录，通过isnan判定。

```
1 a = np.random.rand(2,2)
2 a[0, 1] = np.nan
3 print np.isnan(a)
```

查看全部 ()

```
[[False  True]
 [False False]]
```

nan_to_num可用来将nan替换成0，在后面会介绍到的更高级的模块pandas时，我们将看到pandas提供能指定nan替换值的函数。

```
1 print np.nan_to_num(a)
```

查看全部 ()

```
[[ 0.58144238  0.        ]
 [ 0.26789784  0.48664306]]
```

NumPy还有很多的函数，想详细了解可参考链接http://wiki.scipy.org/Numpy_Example_List (http://wiki.scipy.org/Numpy_Example_List) 和 http://docs.scipy.org/doc/numpy (http://docs.scipy.org/doc/numpy)

最后献上NumPy SciPy Pandas Cheat Sheet

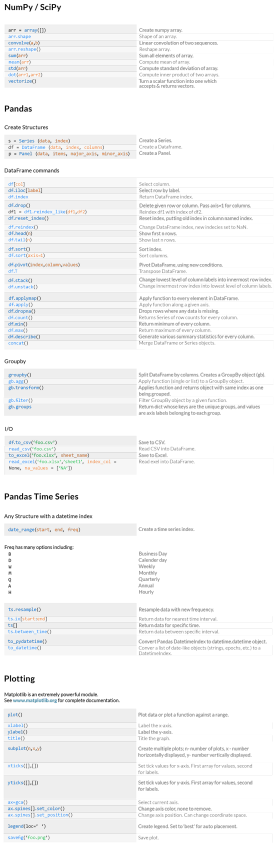

NumPy / SciPy

`arr = array([])`	Create numpy array.
`arr.shape`	Shape of an array.
`convolve(x,y)`	Linear convolution of two sequences.
`arr.reshape()`	Reshape array.
`sum(arr)`	Sum all elements of array.
`mean(arr)`	Compute mean of array.
`std(arr)`	Compute standard deviation of array.
`dot(arr,arr)`	Compute inner product of two arrays.
`vectorize()`	Turns a scalar function into one which accepts & returns vectors.

Pandas

Create Structures

`s = Series (data, index)`	Create a Series.
`df = DataFrame (data, index, columns)`	Create a DataFrame.
`p = Panel (data, items, major_axis, minor_axis)`	Create a Panel.

DataFrame commands

`df[col]`	Select column.
`df.iloc[label]`	Select row by label.
`df.index`	Return DataFrame index.
`df.drop()`	Delete given row or column. Pass axis=1 for columns.
`df1 = df1.reindex_like(df2,df3)`	Reindex df1 with index of df2.
`df.reset_index()`	Reset index, putting old index in column named index.
`df.reindex()`	Change DataFrame index, new indicies set to NaN.
`df.head(n)`	Show first n rows.
`df.tail(n)`	Show last n rows.
`df.sort()`	Sort Index.
`df.sort(cols)`	Sort columns.
`df.pivot(index,columns,values)`	Pivot DataFrame, using new conditions.
`df.T`	Transpose DataFrame.
`df.stack()`	Change lowest level of column labels into innermost row index.
`df.unstack()`	Change innermost row index into lowest level of column labels.
`df.applymap()`	Apply function to every element in DataFrame.
`df.apply()`	Apply function along a given axis.
`df.dropna()`	Drops rows where any data is missing.
`df.count()`	Returns Series of row counts for every column.
`df.min()`	Returns minimum of every column.
`df.max()`	Returns maximum of every column.
`df.describe()`	Generate various summary statistics for every column.
`concat()`	Merge DataFrame or Series objects.

Groupby

`groupby()`	Split DataFrame by columns. Creates a Groupby object (gb).
`gb.agg()`	Apply function (single or list) to a GroupBy object.
`gb.transform()`	Applies function and returns object with same index as one being grouped.
`gb.filter()`	Apply function to object by a given function.
`gb.groups`	Returns dict whose keys are the unique groups, and values are axis labels belonging to each group.

I/O

`df.to_csv('foo.csv')`	Save to CSV.
`read_csv('foo.csv')`	Read CSV into DataFrame.
`to_excel('foo.xlsx', sheet_name)`	Save to Excel.
`read_excel('foo.xlsx','sheet1', index_col = None, na_values = ['NA'])`	Read excel into DataFrame.

Pandas Time Series

Any Structure with a datetime index

`date_range(start, end, freq)`	Create a time series index.

Freq has many options including:

`B`	Business Day
`D`	Calender day
`W`	Weekly
`M`	Monthly
`Q`	Quarterly
`A`	Annual
`H`	Hourly

`ts.resample()`	Resample data with new frequency.
`ts.tz_localize()`	Return data for nearest time interval.
`ts.tz_convert()`	Return data for specific time.
`ts.between_time()`	Return data between specific interval.
`to_pydatetime()`	Convert Pandas DateTimeIndex to datetime.datetime object.
`to_datetime()`	Convert a list of date-like objects (strings, epochs, etc.) to a DateTimeIndex.

Plotting

Matplotlib is an extremely powerful module.
See www.matplotlib.org for complete documentation.

`plot()`	Plot data or plot a function against a range.
`xlabel()`	Label the x-axis.
`ylabel()`	Label the y-axis.
`title()`	Title the graph.
`subplot(x,y,z)`	Create multiple plots; x - number of plots, y - number horizontally displayed, z - number vertically displayed.
`xticks([],[])`	Set tick values for x-axis. First array for values, second for labels.
`yticks([],[])`	Set tick values for y-axis. First array for values, second for labels.
`ax=gca()`	Select current axis.
`ax.spines[].set_color()`	Change axis color, none to remove.
`ax.spines[].set_position()`	Change axis position. Can change coordinate space.
`legend(loc= 1)`	Create legend. Set to 'best' for axis placement.
`savefig('foo.png')`	Save plot.

###参考文献

1. http://wiki.scipy.org/Tentative_NumPy_Tutorial (http://wiki.scipy.org/Tentative_NumPy_Tutorial)
2. Sheppard K. Introduction to Python for econometrics, statistics and data analysis. Self-published, University of Oxford, version, 2012, 2.